STT-4300 — Régression II

Calendrier, projet de session et laboratoires

Julien Miron

31 octobre 2026

Table des matières

1 Calendrier **2**

2 Projet de session **3**
2.1 Projet de session . . . 3
2.1.1 Vue d'ensemble . . . 3
2.1.2 Modalités . . . 3
2.1.3 Choix du jeu de données . . . 4
2.1.4 Livrable final . . . 4
2.1.5 Contenu attendu du rapport . . . 4
2.2 Jalons . . . 5
2.2.1 Jalon 1 : choix du jeu de données . . . 5
2.2.2 Jalon 2 : nettoyage et analyse primaire . . . 5
2.2.3 Jalon 3 : ajustement et début d'inférence . . . 6
2.2.4 Jalon 4 : sélection de variables . . . 7
2.2.5 Jalon 5 : ouverture sur d'autres modèles . . . 7
2.3 Évaluation . . . 8
2.4 Échéances . . . 9

3 Labo 1 **9**

4 Labo 2 **9**

5 Labo 3 **10**

6 Labo 4 **10**

7 Labo 5 **10**

1 Calendrier

> ⚠ La version Brio fait foi
>
> Ce calendrier est fourni à titre indicatif. Les dates officielles des évaluations sont celles qui se trouvent sur **Brio** : en cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut.

Télécharger le calendrier, le projet et les labos (PDF)

Semaine	Date	Sujet	Notes
1	14 janvier	MC + régression logistique	
2	21 janvier	Régression logistique	
3	28 janvier	GLM + régression de Poisson	Évaluation en classe 1
4	4 février	Validation croisée + régularisation	Évaluation en classe 2
5	11 février	Validation croisée + régularisation	Évaluation en classe 3
6	18 février	Révision	Évaluation en classe 4
7	25 février	**EXAMEN**	
8	4 mars	SEMAINE DE LECTURE	
9	11 mars	**Labo 1** : Régression non paramétrique : kNN et estimateur à noyau	**Jalon 1 du projet** : Choix du jeu de données
10	18 mars	**Labo 2** : Régression non linéaire : polynômes et splines	**Jalon 2 du projet** : Nettoyage et analyse primaire
11	25 mars	**Labo 3** : Modèles additifs généralisés (GAM)	**Jalon 3 du projet** : Ajustement et début d'inférence
12	1er avril	**Labo 4** : Synthèse : kNN, noyau, splines et GAM en compétition	**Jalon 4 du projet** : Sélection de variables
13	8 avril	**Labo 5** : Regard critique sur les réponses d'un assistant IA	**Jalon 5 du projet** : Ouverture sur d'autres modèles
14	15 avril	Travail sur le projet	Finalisation du projet
15	22 avril	**PRÉSENTATIONS**	
16	29 avril	**PRÉSENTATIONS**	

STT-4300 — Régression II

2 Projet de session

> **La version Brio fait foi**
>
> Ce document décrit le projet de session à titre indicatif. Les dates de remise sont celles qui se trouvent sur **Brio** : en cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut.

Pondération30 % de la note finale

Équipes3 ou 4 étudiants

2.1 Projet de session

2.1.1 Vue d'ensemble

Le projet de session consiste à mener, en équipe, une analyse complète d'un jeu de données à l'aide d'un GLM : une régression logistique (réponse binaire ou proportion) ou une régression de Poisson (réponse de comptage). Le choix du modèle et du jeu de données revient à votre équipe, sous réserve de mon approbation au Jalon 1 (voir plus bas).

Le projet avance par étapes, en cinq jalons dont les échéances sont les dates des labos. Les jalons et les labos sont deux évaluations distinctes : les labos (7 % chacun) portent sur les méthodes des chapitres 7 à 9 et utilisent des jeux de données fournis, alors que les jalons (2 % chacun) font avancer votre projet sur vos propres données. Le jeudi d'un labo, vous remettez donc le labo et le jalon correspondant. Chaque jalon produit un livrable court qui s'intègre à votre rapport final, de sorte qu'il ne reste pas de gros bloc de travail à la fin de la session.

> **Objectif général**
>
> Au terme du projet, vous devez être capables de passer d'une question concrète à un modèle défendable, c'est-à-dire un modèle dont vous savez expliquer le choix, vérifier l'ajustement, interpréter les coefficients et reconnaître les limites.

2.1.2 Modalités

- Équipes : 3 ou 4 étudiants, formées au Jalon 1 ;
- Dépôt : un dépôt GitHub par équipe, avec un projet R reproductible (`renv` recommandé), auquel je dois avoir accès ;
- Logiciels : tout le code est en R et le rapport est rédigé en Quarto ou en LaTeX. Le document doit se compiler de zéro, sans intervention manuelle.

2.1.3 Choix du jeu de données

Votre jeu de données doit respecter les critères suivants.

1. Une variable réponse Y claire : binaire (ou proportion y_i/n_i) pour la régression logistique, ou comptage pour la régression de Poisson.
2. Au moins $n = 200$ observations et au moins 6 covariables potentielles, avec un mélange de variables quantitatives et qualitatives.
3. Une question de recherche que vous pouvez énoncer en une phrase.
4. Des données libres de droits et sans information permettant d'identifier des personnes.
5. Un peu de désordre, si possible (valeurs manquantes, catégories rares, valeurs aberrantes) : le nettoyage fait partie de l'exercice.

C'est à votre équipe de trouver le jeu de données. Vous pouvez chercher, par exemple, du côté de Données Bleues, Données Québec, de Statistique Canada, du dépôt UCI, de Kaggle ou des données ouvertes de la Ville de Québec (collisions, 311, bacs de recyclage, etc.).

2.1.4 Livrable final

Le projet se termine par une présentation en classe (15 minutes plus 5 minutes de questions) accompagnée d'un produit de communication, au choix de votre équipe :

— une application Shiny qui permet d'explorer le modèle (prédictions selon les valeurs des covariables, effet d'une variable, diagnostics) ;
— un site web Quarto (ou un tableau de bord) racontant l'analyse ;
— un poster scientifique (format 36 × 48 po) ;
— un autre format du même niveau, à me proposer (balado, bande dessinée statistique, vidéo de 5 minutes, etc.).

Quel que soit le format, vous devez aussi remettre un rapport technique qui rassemble les livrables des jalons et la conclusion.

Le produit de communication s'adresse à un public non statisticien, votre présentation doit donc traduire les résultats en langage clair : parlez de rapport de cotes ou de variation en pourcentage du taux, pas seulement de coefficients $\hat{\beta}_j$.

2.1.5 Contenu attendu du rapport

1. Question de recherche et description des données.
2. Nettoyage et analyse exploratoire.
3. Modèle retenu, avec sa justification.
4. Estimation, intervalles de confiance et tests (valeur-p) pour les paramètres d'intérêt.
5. Sélection de variables et comparaison de modèles.
6. Diagnostics et validation (résidus, observations influentes, surdispersion pour Poisson, calibration et courbe ROC pour la logistique, validation croisée).
7. Interprétation, limites et ouverture vers d'autres modèles.
8. Une section « Ce qui pourrait fausser nos conclusions » (biais de sélection, variables omises, différence entre corrélation et causalité). Si les données concernent des personnes, ajoutez une courte réflexion éthique : qui est dans les données et qui n'y est pas ?

2.2 Jalons

Le projet comporte cinq jalons, qui donnent chacun lieu à un livrable court (une à deux pages ou un fichier source). La date de chaque labo sert d'échéance au jalon correspondant, mais le jalon ne fait pas partie du labo : il se fait en dehors des séances, et vous pouvez le terminer avant cette date.

2.2.1 Jalon 1 : choix du jeu de données

Objectif : former les équipes, choisir une question de recherche et valider la faisabilité.

Tâches :

- explorer au moins deux jeux de données candidats avec `str()`, `summary()` et `skimr::skim()` ;
- énoncer une question de recherche et identifier la variable réponse Y ainsi que les covariables potentielles ;
- justifier le choix entre logistique et Poisson ;
- vérifier les critères du choix de jeu de données ci-dessus.

Exemple

Pour un jeu de données de collisions routières par intersection, vous pourriez poser $Y_i \sim \text{Poisson}(\mu_i)$ avec

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip},$$

où t_i est une mesure d'exposition (ici, le trafic moyen) qui entre dans le modèle comme décalage (`offset`).

Livrable : une page de proposition (question, données, variable réponse, modèle envisagé, répartition des tâches). Je l'approuve ou je vous demande des ajustements.

2.2.2 Jalon 2 : nettoyage et analyse primaire

Objectif : connaître vos données avant de modéliser.

Tâches :

- documenter les variables (type, unité, valeurs permises) dans un dictionnaire de données ;
- traiter les valeurs manquantes (quantifier, comprendre le mécanisme, choisir une stratégie et la justifier) ;
- recoder les variables qualitatives (niveaux rares, catégorie de référence) ;
- produire des statistiques descriptives et des graphiques de Y en fonction de chaque covariable ;
- repérer les valeurs aberrantes et les problèmes de colinéarité (corrélations, facteurs d'inflation de la variance) ;
- mettre de côté au hasard 20 % des observations (jeu de réserve) sans y toucher avant le Jalon 5 : elles serviront à évaluer honnêtement votre modèle final.

Faites la mise de côté en premier, avant l'analyse exploratoire : les graphiques, les corrélations et les choix de recodage ne doivent s'appuyer que sur les 80 % restants (`donnees_ent`), sinon l'évaluation finale sur la réserve n'est plus honnête. Dans la suite, `donnees_propres` désigne les données nettoyées complètes et `donnees_ent` l'échantillon d'entraînement (80 %) utilisé aux jalons 3 et 4.

```r
library(tidyverse)
donnees <- read_csv("donnees.csv")

# nettoyage du jeu de données, qui crée `donnees_propres`

# jeu de réserve (20 %) mis de côté en premier, graine fixée pour la reproductibilité
set.seed(4300)
id_reserve <- sample(nrow(donnees_propres), size = round(0.2 * nrow(donnees_propres)))
donnees_reserve <- donnees_propres[id_reserve, ]
donnees_ent <- donnees_propres[-id_reserve, ]   # 80 % : exploration et jalons 3 et 4

# proportion de Y selon une covariable qualitative
donnees_ent |>
  group_by(covariable) |>
  summarise(n = n(), prop = mean(y), .groups = "drop")

# valeurs manquantes
donnees_ent |> summarise(across(everything(), ~ mean(is.na(.x))))
```

Livrable : un fichier source qui part des données brutes et produit les données nettoyées (`donnees_propres`), l'échantillon d'entraînement (`donnees_ent`) et le jeu de réserve, avec une section expliquant chaque décision prise.

Notes de cours utiles : validation croisée (pour le rôle d'un jeu de réserve).

2.2.3 Jalon 3 : ajustement et début d'inférence

Objectif : ajuster un premier GLM et interpréter les résultats.

Tâches :

- ajuster un modèle complet avec `glm()` ;
- interpréter chaque coefficient sur l'échelle du prédicteur linéaire et sur l'échelle naturelle (rapport de cotes $e^{\hat{\beta}_j}$ ou rapport de taux) ;
- construire des intervalles de confiance de Wald et par vraisemblance profilée (`confint()`), puis comparer ;
- effectuer des tests de Wald et des tests du rapport de vraisemblance, en précisant la valeur-p et l'hypothèse testée ;
- tracer l'effet d'une covariable sur la probabilité (ou le taux) prédite, les autres covariables étant fixées.

```r
ajust <- glm(y ~ ., data = donnees_ent, family = binomial)   # ou poisson
summary(ajust)
# RC : rapport de cotes (logistique) ou rapport de taux (Poisson)
exp(cbind(RC = coef(ajust), confint(ajust)))
drop1(ajust, test = "LRT")
```

La fonction `drop1` teste chaque variable par le rapport de vraisemblance en la retirant du modèle complet (les autres étant conservées), ce qui répond à la bonne question ; `anova(ajust, test = "Chisq")` donnerait plutôt des tests séquentiels, qui dépendent de l'ordre des variables dans la formule.

> **Remarque**
>
> Avec la régression de Poisson, vérifiez dès cette étape s'il y a de la surdispersion : comparez la déviance résiduelle à ses degrés de liberté et calculez l'estimateur de Pearson $\tilde{\phi}_P$ (voir la section Surdispersion des notes). Si l'un ou l'autre est nettement supérieur à 1, passez à un modèle quasi-Poisson ou binomial négatif.

Livrable : une page d'interprétation écrite pour un lecteur non statisticien.

Notes de cours utiles : régression logistique et GLM et régression de Poisson.

2.2.4 Jalon 4 : sélection de variables

Objectif : comparer des modèles de façon rigoureuse.

Tâches :

- sélection pas à pas (`step()`) avec l'AIC et le BIC, et discussion des limites de cette approche, notamment l'inférence faite après sélection ;
- régularisation ridge et lasso avec `glmnet`, choix de λ par validation croisée ;
- comparaison du pouvoir prédictif par validation croisée sur `donnees_ent` (taux de bonne classification, AUC et déviance pour la logistique ; erreur quadratique et déviance pour Poisson) ; le jeu de réserve n'est pas touché à ce jalon ;
- examen de la stabilité : les variables retenues changent-elles quand vous rééchantillonnez (bootstrap) ?

```
library(glmnet)
X <- model.matrix(y ~ ., donnees_ent)[, -1]
cv <- cv.glmnet(X, donnees_ent$y, family = "binomial", alpha = 1)   # alpha = 0 pour ridge
coef(cv, s = "lambda.1se")
```

Livrable : un tableau comparatif d'au moins trois modèles (complet, sélectionné, lasso), avec un choix final justifié.

Notes de cours utiles : validation croisée et sélection de variables et régularisation.

2.2.5 Jalon 5 : ouverture sur d'autres modèles

Objectif : déterminer jusqu'où le GLM est adéquat et ce qui pourrait le remplacer ou le compléter.

Tâches (choisissez-en au moins une) :

- ajouter une relation non linéaire par splines ou par un GAM (`mgcv::gam()`) et comparer avec le GLM au moyen de l'AIC et de la validation croisée ;

— essayer une méthode de plus proches voisins ou à noyau pour la prédiction ;
— tester un modèle pour données surdispersées (quasi-Poisson, binomial négatif) ou avec excès de zéros (modèle à inflation de zéros) ;
— comparer avec une méthode d'apprentissage automatique (forêt aléatoire, arbre de décision) et discuter du compromis entre interprétabilité et prédiction.

C'est aussi à ce jalon que le jeu de réserve sert, une seule fois : évaluez-y le modèle final retenu au Jalon 4 (et, s'il y a lieu, le modèle concurrent) pour obtenir une estimation honnête de son erreur sur de nouvelles observations.

```
library(mgcv)
# x1 et x2 : deux covariables quantitatives ; f : une covariable qualitative
gam1 <- gam(y ~ s(x1) + s(x2) + f, data = donnees_ent,
            family = binomial, method = "REML")   # ou poisson
plot(gam1, pages = 1)
AIC(ajust, gam1)
```

Livrable : une demi-page répondant à la question « le GLM suffit-il ? », appuyée par au moins une comparaison chiffrée.

Notes de cours utiles : kNN et estimateur à noyau, splines et GAM.

2.3 Évaluation

Le projet compte pour 30 % de la note finale.

Composante	Pondération
Livrables des jalons (5 × 2 %)	10 %
Rapport technique	10 %
Présentation et produit de communication	7 %
Contribution individuelle (évaluation par les pairs)	3 %
Total	**30 %**

Critères d'évaluation du rapport et de la présentation :

— justesse statistique (modèle adapté, hypothèses vérifiées, inférence correcte) ;
— qualité de l'interprétation (claire, nuancée, liée à la question de départ) ;
— reproductibilité (le document se compile sans intervention) ;
— clarté de la communication (graphiques lisibles, vulgarisation) ;
— profondeur de l'analyse (diagnostics, sélection de modèle, ouverture).

2.4 Échéances

Chaque jalon est dû le jeudi du labo de même numéro (Jalon 1 le jeudi du labo 1, Jalon 2 le jeudi du labo 2, etc.) à 23 h 59 (heure de l'Est) : c'est l'état de la branche `main` du dépôt de votre équipe de projet à cette heure qui est corrigé (voir le calendrier du cours et l'onglet Labos). Vous pouvez remettre un jalon avant cette date. L'équipe du projet n'a pas à être la même que vos équipes de labo.

Jalon	Échéance
Jalon 1 : choix du jeu de données	11 mars
Jalon 2 : nettoyage et analyse primaire	18 mars
Jalon 3 : ajustement et début d'inférence	25 mars
Jalon 4 : sélection de variables	1er avril
Jalon 5 : ouverture sur d'autres modèles	8 avril
Rapport technique et produit de communication	16 avril
Présentations	22 et 29 avril
Évaluation par les pairs	À faire directement après chaque présentation

3 Labo 1

> **Note**
>
> Ce labo sera disponible à partir du 11 mars 2027. En cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut. Merci de m'avertir si vous constatez une incohérence.

4 Labo 2

> **Note**
>
> Ce labo sera disponible à partir du 18 mars 2027. En cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut. Merci de m'avertir si vous constatez une incohérence.

5 Labo 3

> **Note**
>
> Ce labo sera disponible à partir du 25 mars 2027. En cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut. Merci de m'avertir si vous constatez une incohérence.

STT-4300 — Régression II

6 Labo 4

> **Note**
>
> Ce labo sera disponible à partir du 1er avril 2027. En cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut. Merci de m'avertir si vous constatez une incohérence.

STT-4300 — Régression II

7 Labo 5

> **Note**
>
> Ce labo sera disponible à partir du 8 avril 2027. En cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut. Merci de m'avertir si vous constatez une incohérence.