

STT-4300 — Régression II

Calendrier, projet de session et laboratoires

Julien Miron

10 octobre 2026

Table des matières

1	Calendrier	2
2	Projet de session	3
2.1	Projet de session	3
2.1.1	Vue d'ensemble	3
2.1.2	Modalités	3
2.1.3	Choix du jeu de données	4
2.1.4	Livrable final	4
2.1.5	Contenu attendu du rapport	4
2.2	Jalons	5
2.2.1	Jalon 1 : choix du jeu de données	5
2.2.2	Jalon 2 : nettoyage et analyse primaire	5
2.2.3	Jalon 3 : ajustement et début d'inférence	6
2.2.4	Jalon 4 : sélection de variables	7
2.2.5	Jalon 5 : ouverture sur d'autres modèles	7
2.3	Évaluation	8
2.4	Calendrier suggéré	8
3	Labo 1	8
3.1	Objectifs	9
3.2	Mise en contexte	9
3.3	Consignes	9
3.4	Matériel	9
4	Labo 2	10
4.1	Objectifs	10
4.2	Mise en contexte	10
4.3	Consignes	10
4.4	Matériel	11
5	Labo 3	11
5.1	Objectifs	11
5.2	Mise en contexte	11

5.3	Consignes	12
5.4	Matériel	12
6	Labo 4	12
6.1	Objectifs	13
6.2	Mise en contexte	13
6.3	Consignes	13
6.4	Matériel	14
7	Labo 5	14
7.1	Objectifs	14
7.2	Consignes	14
7.3	Remise	15
7.4	Matériel	15

STT-4300 — Régression II

1 Calendrier

 La version Brio fait foi

Ce calendrier est fourni à titre indicatif. La version officielle est celle déposée sur **Brio** : en cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut.

Télécharger le calendrier, le projet et les labos (PDF)

Semaine	Date	Sujet	Notes
1	14 janvier	MC + régression logistique	
2	21 janvier	Régression logistique	
3	28 janvier	GLM + régression de Poisson	
4	4 février	GLM + régression de Poisson	
5	11 février	Validation croisée + régularisation	
6	18 février	Révision	
7	25 février	EXAMEN	
8	4 mars	SEMAINE DE LECTURE	
9	11 mars	Labo 1 : Régression non paramétrique : kNN et estimateur de noyau	Partie 1 du projet : Choix du jeu de données
10	18 mars	Labo 2 : Régression non linéaire : polynômes et splines	Partie 2 du projet : Nettoyage et analyse primaire
11	25 mars	Labo 3 : Modèles additifs généralisés (GAM)	Partie 3 du projet : Ajustement et début d'inférence
12	1 avril	Labo 4 : Synthèse : kNN, noyau, splines et GAM en compétition	Partie 4 du projet : Sélection de variables et validation croisée
13	8 avril	Labo 5 : Regard critique sur les réponses d'un assistant IA	Partie 5 du projet : Ouverture sur d'autres modèles

Semaine	Date	Sujet	Notes
14	15 avril	Travail sur le projet	Finalisation du projet
15	22 avril	PRÉSENTATIONS	
16	29 avril	Labo 16	

STT-4300 — Régression II

2 Projet de session

⚠ La version Brio fait foi

Ce document décrit le projet de session à titre indicatif. La version officielle est celle déposée sur **Brio** : en cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut.

Pondération 50 % de la note finale

Équipes 3 ou 4 étudiants

2.1 Projet de session

2.1.1 Vue d'ensemble

Le projet de session consiste à mener, en équipe, une analyse complète d'un jeu de données à l'aide d'un GLM : une régression logistique (réponse binaire ou proportion) ou une régression de Poisson (réponse de comptage). Le choix du modèle et du jeu de données revient à votre équipe, sous réserve de mon approbation au Jalon 1.

Le projet avance par étapes, au rythme de cinq jalons dont les dates des labos servent d'échéances. Chaque jalon produit un livrable court qui s'intègre à votre rapport final, de sorte qu'il n'y a pas de gros bloc de travail à la fin de la session.

i Objectif général

Passer d'une question concrète à un modèle défendable, c'est-à-dire un modèle dont vous savez expliquer le choix, vérifier l'ajustement, interpréter les coefficients et reconnaître les limites.

2.1.2 Modalités

- Équipes de 3 ou 4 étudiants, formées au Jalon 1.
- Un dépôt GitHub par équipe, avec un projet R reproductible (**renv** recommandé). Je dois avoir accès au dépôt.
- Tout le code est en R et le rapport est rédigé en Quarto ou en LaTeX : le document doit se compiler de zéro sans intervention manuelle.

2.1.3 Choix du jeu de données

Votre jeu de données doit respecter les critères suivants.

1. Une variable réponse Y claire : binaire (ou proportion y_i/n_i) pour la régression logistique, ou comptage pour la régression de Poisson.
2. Au moins $n = 200$ observations et au moins 6 covariables potentielles, avec un mélange de variables quantitatives et qualitatives.
3. Une question de recherche que vous pouvez énoncer en une phrase.
4. Des données libres de droits et sans information permettant d'identifier des personnes.
5. Un peu de désordre (valeurs manquantes, catégories rares, valeurs aberrantes) : le nettoyage fait partie de l'exercice.

Trouvez votre jeu de données, par exemple à partir de Données Québec, de Statistique Canada, du dépôt UCI, de Kaggle ou de données ouvertes de la Ville de Québec (collisions, 311, bacs de recyclage, etc.).

2.1.4 Livrable final

Le projet se termine par une présentation en classe (10 minutes plus 5 minutes de questions) accompagnée d'un produit de communication, au choix de votre équipe :

- une application Shiny qui permet d'explorer le modèle (prédictions selon les valeurs des covariables, effet d'une variable, diagnostics) ;
- un site web Quarto (ou un tableau de bord) racontant l'analyse ;
- un poster scientifique (format 36×48 po) ;
- un autre format du même niveau, à me proposer (balado, bande dessinée statistique, vidéo de 5 minutes, etc.).

Peu importe le format, vous devez aussi remettre un rapport technique de 8 à 12 pages qui rassemble les livrables des jalons et la conclusion.

Le produit de communication s'adresse à un public non statisticien. Votre présentation doit donc traduire les résultats en langage clair : parlez de rapport de cotes ou de variation en pourcentage du taux, pas seulement de coefficients $\hat{\beta}_j$.

2.1.5 Contenu attendu du rapport

1. Question de recherche et description des données.
2. Nettoyage et analyse exploratoire.
3. Modèle retenu, avec sa justification.
4. Estimation, intervalles de confiance et tests (valeur- p) pour les paramètres d'intérêt.
5. Sélection de variables et comparaison de modèles.
6. Diagnostics et validation (résidus, observations influentes, surdispersion pour Poisson, calibration et courbe ROC pour la logistique, validation croisée).
7. Interprétation, limites et ouverture vers d'autres modèles.
8. Une section « Ce qui pourrait fausser nos conclusions » (biais de sélection, variables omises, différence entre corrélation et causalité). Si les données concernent des personnes, ajoutez une courte réflexion éthique : qui est dans les données et qui n'y est pas ?

2.2 Jalons

Le projet comporte cinq jalons. La date de chaque labo sert d'échéance au jalon correspondant, mais vous n'avez pas à attendre le labo pour vous y mettre : un jalon peut être complété avant, il n'est pas nécessaire de le faire en classe pendant le labo. Chaque jalon donne lieu à un livrable court (une à deux pages ou un fichier source).

2.2.1 Jalon 1 : choix du jeu de données

Objectif : former les équipes, choisir une question de recherche et valider la faisabilité.

Tâches :

- explorer au moins deux jeux de données candidats avec `str()`, `summary()` et `skimr::skim()` ;
- énoncer une question de recherche et identifier la variable réponse Y ainsi que les covariables potentielles ;
- justifier le choix entre logistique et Poisson ;
- vérifier les critères du choix de jeu de données ci-dessus.

💡 Exemple

Pour un jeu de données de collisions routières par intersection, vous pourriez poser $Y_i \sim \text{Poisson}(\mu_i)$ avec

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip},$$

où t_i est une mesure d'exposition (ici, le trafic moyen) qui entre dans le modèle comme décalage (`offset`).

Livrable : une page de proposition (question, données, variable réponse, modèle envisagé, répartition des tâches). Je l'approuve ou je demande des ajustements.

2.2.2 Jalon 2 : nettoyage et analyse primaire

Objectif : connaître ses données avant de modéliser.

Tâches :

- documenter les variables (type, unité, valeurs permises) dans un dictionnaire de données ;
- traiter les valeurs manquantes (quantifier, comprendre le mécanisme, choisir une stratégie et la justifier) ;
- recoder les variables qualitatives (niveaux rares, catégorie de référence) ;
- produire des statistiques descriptives et des graphiques de Y en fonction de chaque covariable ;
- repérer les valeurs aberrantes et les problèmes de colinéarité (corrélations, facteurs d'inflation de la variance) ;
- mettre de côté au hasard 20 % des observations (jeu de réserve) sans y toucher avant le Jalon 4 : elles serviront à évaluer honnêtement votre modèle final.

```
library(tidyverse)
donnees <- read_csv("donnees.csv")

# proportion de Y selon une covariable qualitative
donnees |>
  group_by(covariable) |>
  summarise(n = n(), prop = mean(y), .groups = "drop")

# valeurs manquantes
donnees |> summarise(across(everything(), ~ mean(is.na(.x))))
```

Livrable : un fichier source qui part des données brutes et produit les données nettoyées et le jeu de réserve, avec une section expliquant chaque décision prise.

2.2.3 Jalon 3 : ajustement et début d'inférence

Objectif : ajuster un premier GLM et interpréter les résultats.

Tâches :

- ajuster un modèle complet avec `glm()` ;
- interpréter chaque coefficient sur l'échelle du prédicteur linéaire et sur l'échelle naturelle (rapport de cotes $e^{\hat{\beta}_j}$ ou rapport de taux) ;
- construire des intervalles de confiance de Wald et par vraisemblance profilée (`confint()`), puis comparer ;
- effectuer des tests de Wald et des tests du rapport de vraisemblance, en précisant la valeur- p et l'hypothèse testée ;
- tracer l'effet d'une covariable sur la probabilité (ou le taux) prédite, les autres covariables étant fixées.

```
ajust <- glm(y ~ ., data = donnees_propres, family = binomial) # ou poisson
summary(ajust)
exp(cbind(OR = coef(ajust), confint(ajust)))
anova(ajust, test = "Chisq")
```

i Remarque

Pour Poisson, vérifiez dès cette étape la surdispersion en comparant la déviance résiduelle à ses degrés de liberté. Si le rapport est nettement supérieur à 1, passez à un modèle quasi-Poisson ou binomial négatif.

Livrable : une page d'interprétation écrite pour un lecteur non statisticien.

2.2.4 Jalon 4 : sélection de variables

Objectif : comparer des modèles de façon rigoureuse.

Tâches :

- sélection pas à pas (`step()`) avec l'AIC et le BIC, et discussion des limites de cette approche, notamment l'inférence faite après sélection ;
- régularisation ridge et lasso avec `glmnet`, choix de λ par validation croisée ;
- comparaison du pouvoir prédictif par validation croisée, puis une évaluation finale du modèle retenu sur le jeu de réserve (taux de bonne classification, AUC et déviance pour la logistique ; erreur quadratique et déviance pour Poisson) ;
- examen de la stabilité : les variables retenues changent-elles si l'on rééchantillonne (bootstrap) ?

```
library(glmnet)
X <- model.matrix(y ~ ., donnees_propres)[, -1]
cv <- cv.glmnet(X, donnees_propres$y, family = "binomial", alpha = 1)
coef(cv, s = "lambda.1se")
```

Livrable : un tableau comparatif d'au moins trois modèles (complet, sélectionné, lasso), avec un choix final justifié.

2.2.5 Jalon 5 : ouverture sur d'autres modèles

Objectif : voir jusqu'où le GLM est adéquat et ce qui pourrait le remplacer ou le compléter.

Tâches (choisissez-en au moins une) :

- ajouter une relation non linéaire par splines ou par un GAM (`mgcv::gam()`) et comparer avec le GLM au moyen de l'AIC et de la validation croisée ;
- essayer une méthode de plus proches voisins ou à noyau pour la prédiction ;
- tester un modèle pour données surdispersées (quasi-Poisson, binomial négatif) ou avec excès de zéros (modèle à inflation de zéros) ;
- comparer avec une méthode d'apprentissage automatique (forêt aléatoire, arbre de décision) et discuter du compromis entre interprétabilité et prédiction.

```
library(mgcv)
gam1 <- gam(y ~ s(diametre) + s(hauteur) + espece, data = donnees_propres,
            family = binomial, method = "REML")
plot(gam1, pages = 1)
AIC(ajust, gam1)
```

Livrable : une demi-page répondant à la question « le GLM suffit-il ? », appuyée par au moins une comparaison chiffrée.

2.3 Évaluation

Le projet compte pour 45 % de la note finale.

Composante	Pondération
Livrables des jalons ($5 \times 3 \%$)	15 %
Rapport technique	15 %
Présentation et produit de communication	10 %
Contribution individuelle (évaluation par les pairs)	5 %
Total	45 %

Critères d'évaluation du rapport et de la présentation :

- justesse statistique (modèle adapté, hypothèses vérifiées, inférence correcte) ;
- qualité de l'interprétation (claire, nuancée, liée à la question de départ) ;
- reproductibilité (le document se compile sans intervention) ;
- clarté de la communication (graphiques lisibles, vulgarisation) ;
- profondeur de l'analyse (diagnostics, sélection de modèle, ouverture).

2.4 Calendrier suggéré

La date de chaque labo sert d'échéance au jalon correspondant (voir le [calendrier du cours](#) et l'onglet [Labos](#)). Vous pouvez compléter un jalon avant cette date ; il n'est pas nécessaire d'attendre le labo, ni de faire le travail en classe.

Jalon	Échéance
Jalon 1 : choix du jeu de données	Labo 1 — 11 mars
Jalon 2 : nettoyage et analyse primaire	Labo 2 — 18 mars
Jalon 3 : ajustement et début d'inférence	Labo 3 — 25 mars
Jalon 4 : sélection de variables	Labo 4 — 1 avril
Jalon 5 : ouverture sur d'autres modèles	Labo 5 — 8 avril
Présentations	22 avril

STT-4300 — Régression II

3 Labo 1

Date 11 mars 2026

Sujet Régression non paramétrique : kNN et estimateur de noyau

3.1 Objectifs

- Implémenter et comparer l'estimateur des k plus proches voisins (k NN) et l'estimateur de noyau de Nadaraya-Watson.
- Comprendre, de façon empirique, le compromis biais-variance associé au choix de k et de la fenêtre h .
- Sélectionner k et h par validation croisée et comparer les courbes ajustées obtenues.

3.2 Mise en contexte

On utilise le jeu de données `arbres` ([télécharger](#)), décrit dans les notes de cours : 200 arbres de l'inventaire forestier du Québec, tirés de [donneesbleues.ca](#). La réponse Y est la hauteur (`height_m`, en m) et la variable explicative X est le diamètre à hauteur de poitrine (`diameter_cm`, en cm), comme dans le chapitre sur la régression non paramétrique.

```
library(FNN)
library(KernSmooth)
arbres <- read.csv("arbres.csv")
```

3.3 Consignes

1. Produire un nuage de points de la hauteur en fonction du diamètre et discuter brièvement pourquoi une relation linéaire semble inadéquate. Noter aussi deux particularités du jeu de données : plusieurs arbres ont exactement le même diamètre, et les gros arbres sont rares.
2. À l'aide de `knn.reg` (librairie `FNN`), ajuster l'estimateur k NN pour plusieurs valeurs de k (par exemple $k = 2, 5, 9, 25, 60$). Superposer les courbes ajustées au nuage de points et commenter l'effet de k sur la rugosité de la courbe et sur son comportement pour les gros arbres.
3. Utiliser le critère PRESS de `knn.reg` (LOOCV) pour sélectionner $k_{\min}$. Comparer avec la valeur $k_{\min} = 9$ obtenue dans les notes. Que se passe-t-il pour les diamètres ex æquo ?
4. À l'aide de `locpoly` (librairie `KernSmooth`, `degree = 0`), ajuster l'estimateur de Nadaraya-Watson pour plusieurs valeurs de la fenêtre h (en cm). Encore une fois, illustrer l'effet de h sur la courbe ajustée.
5. Choisir h par validation croisée (vous pouvez coder vous-même une boucle de LOOCV ou de K -fold CV, ou utiliser la formule explicite des notes) et comparer la courbe obtenue à celle de k NN avec $k_{\min}$.
6. En une dizaine de lignes, comparer les deux approches : avantages, inconvénients, et situations où l'une serait préférable à l'autre (notamment en présence de plusieurs variables explicatives, par exemple le diamètre et l'âge ; voir la distance de Mahalanobis dans les notes).

3.4 Matériel

- Notes de cours : [Régression non paramétrique — \$k\$ NN et noyau](#)
- Données : [arbres.csv](#)
- Librairies R : `FNN`, `KernSmooth`

4 Labo 2

Date 18 mars 2026

Sujet Régression non linéaire : polynômes et splines

4.1 Objectifs

- Ajuster des modèles de régression polynomiale, par fonctions constantes par morceaux, et par splines de régression.
- Choisir le degré du polynôme (ou le nombre de nœuds) par un critère d'information (AIC/BIC) et par validation croisée.
- Comprendre l'intérêt des splines naturelles et des splines de lissage (`smooth.spline`) par rapport aux splines de régression classiques.

4.2 Mise en contexte

On utilise le jeu de données `qualite_air` ([télécharger](#), 28 Mo), décrit dans les notes de cours : mesures horaires 2025 des stations du Réseau de surveillance de la qualité de l'air du Québec, tirées de [donneesbleues.ca](#). Comme dans le chapitre sur les splines, on retient les mesures d'ozone (O3, en ppb) de juin, juillet et août à la station de Longueuil ; la réponse Y est la concentration d'ozone et la variable explicative X est l'heure de la journée, de 0 à 23.

```
library(splines)
air <- read.csv("qualite_air.csv", fileEncoding = "UTF-8-BOM")
air$heure <- as.integer(substr(air$Date_Heure, 12, 13))
air$mois <- as.integer(substr(air$Date_Heure, 6, 7))
ozone <- subset(air, Station == "06600 - Longueuil" & mois %in% 6:8 & !is.na(O3))
```

4.3 Consignes

1. Ajuster des régressions polynomiales de degré $p = 1, 2, 3, 5, 10$ (`lm(O3 ~ poly(heure, p, raw = TRUE))`). Superposer les courbes ajustées au nuage de points et commenter : quel degré minimal faut-il pour représenter le cycle journalier ? Que fait le degré 10 près de minuit ?
2. Sélectionner le degré p à l'aide de l'AIC et du BIC, puis à l'aide de la validation croisée (LOOCV ou 10-fold). Les critères mènent-ils à la même valeur de p ? Pourquoi sont-ils si plats au-delà d'un certain degré ?
3. Ajuster un modèle à fonctions constantes par morceaux avec `cut(heure, K)` pour quelques valeurs de K , dont $K = 24$. Que représente $\hat{f}$ dans ce dernier cas ? Comparer à la régression polynomiale, visuellement et par validation croisée.
4. Ajuster une spline de régression cubique avec `bs(heure, knots = ...)` pour un choix de nœuds que vous justifierez, puis une spline naturelle avec `ns(heure, df = 4)`. Comparer les deux courbes, en particulier si on les prolonge au-delà de la plage des données.

5. Ajuster une spline de lissage avec `smooth.spline(ozone$heure, ozone$O3)`. Rapporter les degrés de liberté effectifs sélectionnés et comparer la courbe obtenue aux splines de régression du point 4. Essayer ensuite `cv = TRUE` : que dit R, et pourquoi ? Combien de nœuds la spline de lissage utilise-t-elle ici ?
6. Construire un intervalle de confiance ponctuel pour $f(x)$ à 16 h, pour le modèle polynomial retenu au point 2, et le comparer à l'intervalle de prédiction pour une nouvelle mesure. Pourquoi sont-ils si différents ?
7. Rédiger une courte conclusion (5-10 lignes) comparant l'ensemble des méthodes du labo selon : flexibilité, risque de surajustement, interprétabilité, et facilité d'implémentation.

4.4 Matériel

- Notes de cours : [Régression non linéaire — polynômes, fonctions par morceaux et splines](#)
- Données : [qualite_air.csv](#)
- Librairies R : `splines`

STT-4300 — Régression II

5 Labo 3

Date 25 mars 2026

Sujet Modèles additifs généralisés (GAM)

5.1 Objectifs

- Ajuster un modèle additif avec la librairie `mgcv` et interpréter les effets lissés de chaque variable.
- Comprendre le rôle du paramètre de lissage et des degrés de liberté effectifs dans le compromis biais-variance.
- Vérifier l'hypothèse d'additivité et étendre les GAM au cas d'une réponse non gaussienne (GAM logistique).

5.2 Mise en contexte

On reprend le jeu de données `qualite_air` ([télécharger](#)) du labo 2, mais sur l'année entière : les mesures horaires d'ozone de 2025 à la station de Longueuil, soit environ 8 700 observations. La réponse Y est la concentration d'ozone (`O3`) et il y a deux variables explicatives, l'heure de la journée (`heure`) et le jour de l'année (`jour`, de 1 à 365). Pour le GAM logistique, on utilisera le jeu de données `arbres` ([télécharger](#)) du labo 1.

```
library(mgcv)
air <- read.csv("qualite_air.csv", fileEncoding = "UTF-8-BOM")
air$heure <- as.integer(substr(air$Date_Heure, 12, 13))
air$jour <- as.integer(format(as.Date(substr(air$Date_Heure, 1, 10)), "%j"))
longueuil <- subset(air, Station == "06600 - Longueuil" & !is.na(O3))
```

5.3 Consignes

1. Ajuster le modèle additif `mod1 <- gam(O3 ~ s(heure) + s(jour), data = longueuil)`. Afficher les effets partiels estimés (`plot(mod1, pages = 1)`) et commenter leur forme : sont-ils linéaires ? Que représente chacun des deux cycles ? Justifient-ils l'usage d'un GAM plutôt que d'un modèle linéaire ?
2. Examiner `summary(mod1)` : rapporter les degrés de liberté effectifs de chaque terme lissé et la déviance expliquée. Tester $H_0 : f_j \equiv 0$ pour chacune des deux variables. L'un des deux termes utilise presque tous ses degrés de liberté disponibles : lequel, et qu'est-ce que cela suggère ?
3. Comparer le modèle additif à un modèle linéaire usuel (`lm(O3 ~ heure + jour)`) et à un modèle polynomial (par exemple degré 5 pour chaque variable) à l'aide de l'AIC et d'une estimation de l'erreur de prédiction par validation croisée. Réfléchir à ce que vaut une validation croisée par blocs tirés au hasard quand les observations sont des heures consécutives.
4. Faire varier artificiellement le paramètre de lissage du terme `s(jour)` (argument `sp`, en donnant au terme une base plus riche avec `k = 30`) pour illustrer l'effet de $\lambda \rightarrow 0$ et $\lambda \rightarrow \infty$ sur la courbe ajustée. Que choisit le GCV avec cette base plus riche, et pourquoi ?
5. Le modèle additif suppose que le cycle journalier a la même forme toute l'année. Ajuster une surface `te(heure, jour)`, puis un modèle avec effets principaux et interaction pure, `s(heure) + s(jour) + ti(heure, jour)`. L'hypothèse d'additivité tient-elle ? Discuter de ce que l'interaction apporte, et de ce qu'elle coûte.
6. GAM logistique. Sur `arbres`, poser $Y = 1$ si l'arbre est dans la strate inférieure du couvert (`canopy_stratum` égal à `Intermédiaire` ou `Opprimé`) et ajuster `gam(Y ~ s(diameter_cm) + espece, family = binomial)`. Représenter la probabilité ajustée en fonction du diamètre et comparer à une régression logistique usuelle. Que valent les degrés de liberté effectifs, et qu'en conclure ?

5.4 Matériel

- Notes de cours : [Modèles additifs et modèles additifs généralisés \(GAM\)](#)
- Données : [qualite_air.csv](#), [arbres.csv](#)
- Librairies R : `mgcv`

STT-4300 — Régression II

6 Labo 4

Date 1er avril 2026

Sujet Synthèse : kNN, noyau, splines et GAM en compétition

6.1 Objectifs

- Comparer, sur un même jeu de données, l'ensemble des méthodes non paramétriques et non linéaires vues jusqu'ici (kNN, noyau, splines, GAM).
- Estimer et comparer l'erreur de prédiction test de chaque méthode par validation croisée.
- Développer un jugement critique sur le choix d'une méthode selon le contexte (nombre de variables, interprétabilité recherchée, taille de l'échantillon).

6.2 Mise en contexte

On reprend le jeu de données `qualite_air` ([télécharger](#)), mais à une autre station : Québec – Vieux-Limoilou. Comme aux labos 2 et 3, la réponse Y est la concentration d'ozone (O3) et la variable explicative X est l'heure de la journée ; on retient les mois de juin, juillet et août. Pour la partie multivariée, on utilisera l'année entière et les autres contaminants mesurés à la station : le monoxyde de carbone (CO), les particules fines (PM2.5-T640) et le carbone suie (BC_880nm).

```
library(FNN)
library(KernSmooth)
library(splines)
library(mgcv)
air <- read.csv("qualite_air.csv", fileEncoding = "UTF-8-BOM")
air$heure <- as.integer(substr(air$Date_Heure, 12, 13))
air$mois <- as.integer(substr(air$Date_Heure, 6, 7))
air$jour <- as.integer(format(as.Date(substr(air$Date_Heure, 1, 10)), "%j"))
quebec <- subset(air, Station == "03006 - Québec - Vieux-Limoilou")
ete <- subset(quebec, mois %in% 6:8 & !is.na(O3))
```

6.3 Consignes

1. Partitionner les données en un ensemble d'entraînement (70 %) et un ensemble test (30 %), ou prévoir une procédure de validation croisée à $K = 10$ plis réutilisable pour toutes les méthodes suivantes. Réfléchir aux conséquences d'un tirage au hasard parmi des heures consécutives.
2. Ajuster, sur l'ensemble d'entraînement, chacun des modèles suivants pour prédire O3 en fonction de `heure` :
 - un modèle linéaire simple (référence) ;
 - un estimateur kNN (`knn.reg`), avec k choisi par validation croisée ;
 - un estimateur de noyau (`locpoly` ou la formule des poids), avec h choisi par validation croisée ;
 - une spline de lissage (`smooth.spline`, en justifiant le choix entre GCV et `cv = TRUE`) ;
 - un GAM univarié (`gam(O3 ~ s(heure))`).
3. Pour chaque méthode, calculer l'erreur quadratique moyenne sur l'ensemble test (ou moyenne des erreurs de validation croisée). Présenter les résultats dans un tableau.
4. Superposer, sur un même graphique, les cinq courbes ajustées par rapport au nuage de points. Commenter les ressemblances et différences.

5. Extension multivariée. Sur l'année entière, ajuster un GAM avec plusieurs prédicteurs, par exemple `gam(O3 ~ s(heure) + s(jour) + s(CO) + s(PM25) + s(BC))`, après avoir renommé les colonnes PM2.5-T640 et BC_880nm et retiré les heures où une mesure manque. Comparer son erreur de prédiction test à celle du modèle linéaire multiple correspondant et à celle du GAM à deux cycles du labo 3. Quelles variables semblent avoir un effet non linéaire marqué ? Comment ces effets s'interprètent-ils chimiquement ?
6. Rédiger une conclusion (15-20 lignes) qui répond à la question : *dans quelles circonstances choisiriez-vous kNN, le noyau, les splines, ou un GAM ?* Appuyez votre réponse sur vos résultats numériques et sur des arguments de flexibilité, de fléau de la dimension, et d'interprétabilité.

6.4 Matériel

- Notes de cours : [kNN et noyau](#), [Splines](#), [GAM](#)
- Données : [qualite_air.csv](#)
- Librairies R : `FNN`, `KernSmooth`, `splines`, `mgcv`

STT-4300 — Régression II

7 Labo 5

Date 8 avril 2026

Sujet Regard critique sur les réponses d'un assistant IA (Claude)

Un labo différent

Ce labo ne porte pas sur l'implémentation d'une méthode, mais sur votre capacité à évaluer de façon critique une explication statistique produite par un assistant conversationnel. L'objectif n'est pas de disqualifier l'outil, mais d'apprendre à le confronter à vos propres connaissances plutôt qu'à lui faire confiance aveuglément.

7.1 Objectifs

- Formuler une question technique précise sur la matière du cours (régression non paramétrique, régression non linéaire, GAM).
- Évaluer la justesse, la complétude et la clarté d'une réponse générée par l'assistant, en s'appuyant sur les notes de cours et vos propres calculs.
- Identifier les forces et les limites d'un assistant IA comme outil d'apprentissage en statistique.

7.2 Consignes

1. Choisissez **une** question précise (pas une question trop générale du type « explique-moi les splines ») portant sur un concept des labos 1 à 4. Quelques exemples, à adapter ou remplacer par une question de votre cru :

- « Pourquoi la variance de l'estimateur kNN est-elle σ^2/k , et pourquoi ce résultat suppose-t-il $Var[\epsilon_i]$ constante ? »
 - « Pourquoi les splines naturelles imposent-elles la linéarité de f aux extrémités, et en quoi cela réduit-il la variance de $\hat{f}(x)$ près des bords ? »
 - « Quelle est la différence entre la validation croisée ordinaire (OCV) et la validation croisée généralisée (GCV) pour choisir le paramètre de lissage d'un GAM ? »
 - « Pourquoi dit-on que les modèles additifs permettent d'éviter le fléau de la dimension auquel se heurtent les estimateurs à noyau ? »
2. Posez votre question à l'assistant et conservez l'échange intégral (question et réponse complète, sans l'éditer).
 3. Rédigez une évaluation critique de la réponse obtenue, structurée en quatre points :
 - **Exactitude** : la réponse est-elle correcte ? Si elle contient une erreur, une imprécision ou une simplification abusive, identifiez-la précisément et expliquez pourquoi c'est incorrect (appuyez-vous sur les notes de cours ou sur un calcul).
 - **Complétude** : la réponse omet-elle une nuance ou une hypothèse importante (p. ex. une condition de régularité, un cas particulier) ?
 - **Clarté et niveau** : la réponse est-elle adaptée au niveau du cours ? Est-elle trop vague, trop technique, ou truffée de jargon non défini ?
 - **Verdict global** : sur une échelle qualitative (excellente / correcte mais incomplète / partiellement erronée / erronée), que donneriez-vous à cette réponse, et pourquoi ?
 4. Précisez ce que vous auriez pu ajouter ou modifier dans votre question pour obtenir une réponse plus complète ou plus précise de l'assistant.
 5. Si la réponse contient une erreur ou une lacune, rédigez **vous-même** une version corrigée ou complétée du passage problématique (quelques phrases suffisent).
 6. En quelques lignes, commentez : dans quel contexte un assistant comme Claude est-il utile pour apprendre les méthodes de ce cours ?

7.3 Remise

- L'échange complet avec Claude (question et réponse, non modifiés).
- Votre évaluation critique (points 3-5 ci-dessus).

7.4 Matériel

- Notes de cours : [kNN et noyau](#), [Splines](#), [GAM](#)
- Un compte donnant accès à Claude ([claud.ai](#)) ou à un autre assistant conversationnel équivalent