

# STT-4300 — Régression II

Calendrier, projet de session et laboratoires

Julien Miron

9 octobre 2026

## Table des matières

|          |                                                     |          |
|----------|-----------------------------------------------------|----------|
| <b>1</b> | <b>Calendrier</b>                                   | <b>2</b> |
| <b>2</b> | <b>Projet de session</b>                            | <b>2</b> |
| 2.1      | Projet de session . . . . .                         | 3        |
| 2.1.1    | Vue d’ensemble . . . . .                            | 3        |
| 2.1.2    | Modalités . . . . .                                 | 3        |
| 2.1.3    | Choix du jeu de données . . . . .                   | 3        |
| 2.1.4    | Livrable final . . . . .                            | 4        |
| 2.1.5    | Contenu attendu du rapport . . . . .                | 4        |
| 2.2      | Jalons . . . . .                                    | 4        |
| 2.2.1    | Jalon 1 : choix du jeu de données . . . . .         | 4        |
| 2.2.2    | Jalon 2 : nettoyage et analyse primaire . . . . .   | 5        |
| 2.2.3    | Jalon 3 : ajustement et début d’inférence . . . . . | 6        |
| 2.2.4    | Jalon 4 : sélection de variables . . . . .          | 6        |
| 2.2.5    | Jalon 5 : ouverture sur d’autres modèles . . . . .  | 7        |
| 2.3      | Évaluation . . . . .                                | 7        |
| 2.4      | Calendrier suggéré . . . . .                        | 8        |
| <b>3</b> | <b>Labo 1</b>                                       | <b>8</b> |
| <b>4</b> | <b>Labo 2</b>                                       | <b>8</b> |
| <b>5</b> | <b>Labo 3</b>                                       | <b>8</b> |
| <b>6</b> | <b>Labo 4</b>                                       | <b>9</b> |
| <b>7</b> | <b>Labo 5</b>                                       | <b>9</b> |

STT-4300 — Régression II

# 1 Calendrier

⚠ La version Brio fait foi

Ce calendrier est fourni à titre indicatif. La version officielle est celle déposée sur **Brio** : en cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut.

Télécharger le calendrier, le projet et les labos (PDF)

| Semaine | Date       | Sujet                                                                    | Notes                                                                    |
|---------|------------|--------------------------------------------------------------------------|--------------------------------------------------------------------------|
| 1       | 14 janvier | MC + régression logistique                                               |                                                                          |
| 2       | 21 janvier | Régression logistique                                                    |                                                                          |
| 3       | 28 janvier | GLM + régression de Poisson                                              |                                                                          |
| 4       | 4 février  | GLM + régression de Poisson                                              |                                                                          |
| 5       | 11 février | Validation croisée + régularisation                                      |                                                                          |
| 6       | 18 février | Révision                                                                 |                                                                          |
| 7       | 25 février | <b>EXAMEN</b>                                                            |                                                                          |
| 8       | 4 mars     | SEMAINE DE LECTURE                                                       |                                                                          |
| 9       | 11 mars    | <b>Labo 1</b> : Régression non paramétrique : kNN et estimateur de noyau | <b>Partie 1 du projet</b> : Choix du jeu de données                      |
| 10      | 18 mars    | <b>Labo 2</b> : Régression non linéaire : polynômes et splines           | <b>Partie 2 du projet</b> : Nettoyage et analyse primaire                |
| 11      | 25 mars    | <b>Labo 3</b> : Modèles additifs généralisés (GAM)                       | <b>Partie 3 du projet</b> : Ajustement et début d'inférence              |
| 12      | 1 avril    | <b>Labo 4</b> : Synthèse : kNN, noyau, splines et GAM en compétition     | <b>Partie 4 du projet</b> : Sélection de variables et validation croisée |
| 13      | 8 avril    | <b>Labo 5</b> : Regard critique sur les réponses d'un assistant IA       | <b>Partie 5 du projet</b> : Ouverture sur d'autres modèles               |
| 14      | 15 avril   | Travail sur le projet                                                    | Finalisation du projet                                                   |
| 15      | 22 avril   | Présentations                                                            |                                                                          |
| 16      | 29 avril   | Labo 16                                                                  |                                                                          |

STT-4300 — Régression II

## 2 Projet de session

⚠ La version Brio fait foi

Ce document décrit le projet de session à titre indicatif. La version officielle est celle déposée sur **Brio** : en cas de doute ou de différence entre les deux, c'est l'information sur **Brio** qui prévaut.

Pondération 50 % de la note finale

Équipes 3 ou 4 étudiants

## 2.1 Projet de session

### 2.1.1 Vue d'ensemble

Le projet de session consiste à mener, en équipe, une analyse complète d'un jeu de données à l'aide d'un GLM : une régression logistique (réponse binaire ou proportion) ou une régression de Poisson (réponse de comptage). Le choix du modèle et du jeu de données revient à votre équipe, sous réserve de mon approbation au Jalon 1.

Le projet avance par étapes, au rythme de cinq jalons dont les dates des labos servent d'échéances. Chaque jalon produit un livrable court qui s'intègre à votre rapport final, de sorte qu'il n'y a pas de gros bloc de travail à la fin de la session.

#### Objectif général

Passer d'une question concrète à un modèle défendable, c'est-à-dire un modèle dont vous savez expliquer le choix, vérifier l'ajustement, interpréter les coefficients et reconnaître les limites.

### 2.1.2 Modalités

- Équipes de 3 ou 4 étudiants, formées au Jalon 1.
- Un dépôt GitHub par équipe, avec un projet R reproductible (`renv` recommandé). Je dois avoir accès au dépôt.
- Tout le code est en R et le rapport est rédigé en Quarto ou en LaTeX : le document doit se compiler de zéro sans intervention manuelle.

### 2.1.3 Choix du jeu de données

Votre jeu de données doit respecter les critères suivants.

1. Une variable réponse  $Y$  claire : binaire (ou proportion  $y_i/n_i$ ) pour la régression logistique, ou comptage pour la régression de Poisson.
2. Au moins  $n = 200$  observations et au moins 6 covariables potentielles, avec un mélange de variables quantitatives et qualitatives.
3. Une question de recherche que vous pouvez énoncer en une phrase.
4. Des données libres de droits et sans information permettant d'identifier des personnes.
5. Un peu de désordre (valeurs manquantes, catégories rares, valeurs aberrantes) : le nettoyage fait partie de l'exercice.

Trouvez votre jeu de données, par exemple à partir de Données Québec, de Statistique Canada, du dépôt UCI, de Kaggle ou de données ouvertes de la Ville de Québec (collisions, 311, bacs de recyclage, etc.).

### 2.1.4 Livrable final

Le projet se termine par une présentation en classe (10 minutes plus 5 minutes de questions) accompagnée d'un produit de communication, au choix de votre équipe :

- une application Shiny qui permet d'explorer le modèle (prédictions selon les valeurs des covariables, effet d'une variable, diagnostics) ;
- un site web Quarto (ou un tableau de bord) racontant l'analyse ;
- un poster scientifique (format  $36 \times 48$  po) ;
- un autre format du même niveau, à me proposer (balado, bande dessinée statistique, vidéo de 5 minutes, etc.).

Peu importe le format, vous devez aussi remettre un rapport technique de 8 à 12 pages qui rassemble les livrables des jalons et la conclusion.

Le produit de communication s'adresse à un public non statisticien. Votre présentation doit donc traduire les résultats en langage clair : parlez de rapport de cotes ou de variation en pourcentage du taux, pas seulement de coefficients  $\hat{\beta}_j$ .

### 2.1.5 Contenu attendu du rapport

1. Question de recherche et description des données.
2. Nettoyage et analyse exploratoire.
3. Modèle retenu, avec sa justification.
4. Estimation, intervalles de confiance et tests (valeur- $p$ ) pour les paramètres d'intérêt.
5. Sélection de variables et comparaison de modèles.
6. Diagnostics et validation (résidus, observations influentes, surdispersion pour Poisson, calibration et courbe ROC pour la logistique, validation croisée).
7. Interprétation, limites et ouverture vers d'autres modèles.
8. Une section « Ce qui pourrait fausser nos conclusions » (biais de sélection, variables omises, différence entre corrélation et causalité). Si les données concernent des personnes, ajoutez une courte réflexion éthique : qui est dans les données et qui n'y est pas ?

## 2.2 Jalons

Le projet comporte cinq jalons. La date de chaque labo sert d'échéance au jalon correspondant, mais vous n'avez pas à attendre le labo pour vous y mettre : un jalon peut être complété avant, il n'est pas nécessaire de le faire en classe pendant le labo. Chaque jalon donne lieu à un livrable court (une à deux pages ou un fichier source).

### 2.2.1 Jalon 1 : choix du jeu de données

Objectif : former les équipes, choisir une question de recherche et valider la faisabilité.

Tâches :

- explorer au moins deux jeux de données candidats avec `str()`, `summary()` et `skimr::skim()` ;

- énoncer une question de recherche et identifier la variable réponse  $Y$  ainsi que les covariables potentielles ;
- justifier le choix entre logistique et Poisson ;
- vérifier les critères du choix de jeu de données ci-dessus.

#### 💡 Exemple

Pour un jeu de données de collisions routières par intersection, vous pourriez poser  $Y_i \sim \text{Poisson}(\mu_i)$  avec

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip},$$

où  $t_i$  est une mesure d'exposition (ici, le trafic moyen) qui entre dans le modèle comme décalage (**offset**).

Livrable : une page de proposition (question, données, variable réponse, modèle envisagé, répartition des tâches). Je l'approuve ou je demande des ajustements.

### 2.2.2 Jalon 2 : nettoyage et analyse primaire

Objectif : connaître ses données avant de modéliser.

Tâches :

- documenter les variables (type, unité, valeurs permises) dans un dictionnaire de données ;
- traiter les valeurs manquantes (quantifier, comprendre le mécanisme, choisir une stratégie et la justifier) ;
- recoder les variables qualitatives (niveaux rares, catégorie de référence) ;
- produire des statistiques descriptives et des graphiques de  $Y$  en fonction de chaque covariable ;
- repérer les valeurs aberrantes et les problèmes de colinéarité (corrélations, facteurs d'inflation de la variance) ;
- mettre de côté au hasard 20 % des observations (jeu de réserve) sans y toucher avant le Jalon 4 : elles serviront à évaluer honnêtement votre modèle final.

```
library(tidyverse)
donnees <- read_csv("donnees.csv")

# proportion de Y selon une covariable qualitative
donnees |>
  group_by(covariable) |>
  summarise(n = n(), prop = mean(y), .groups = "drop")

# valeurs manquantes
donnees |> summarise(across(everything(), ~ mean(is.na(.x))))
```

Livrable : un fichier source qui part des données brutes et produit les données nettoyées et le jeu de réserve, avec une section expliquant chaque décision prise.

### 2.2.3 Jalon 3 : ajustement et début d'inférence

Objectif : ajuster un premier GLM et interpréter les résultats.

Tâches :

- ajuster un modèle complet avec `glm()` ;
- interpréter chaque coefficient sur l'échelle du prédicteur linéaire et sur l'échelle naturelle (rapport de cotes  $e^{\hat{\beta}_j}$  ou rapport de taux) ;
- construire des intervalles de confiance de Wald et par vraisemblance profilée (`confint()`), puis comparer ;
- effectuer des tests de Wald et des tests du rapport de vraisemblance, en précisant la valeur- $p$  et l'hypothèse testée ;
- tracer l'effet d'une covariable sur la probabilité (ou le taux) prédite, les autres covariables étant fixées.

```
ajust <- glm(y ~ ., data = donnees_propres, family = binomial) # ou poisson
summary(ajust)
exp(cbind(OR = coef(ajust), confint(ajust)))
anova(ajust, test = "Chisq")
```

#### **i** Remarque

Pour Poisson, vérifiez dès cette étape la surdispersion en comparant la déviance résiduelle à ses degrés de liberté. Si le rapport est nettement supérieur à 1, passez à un modèle quasi-Poisson ou binomial négatif.

Livrable : une page d'interprétation écrite pour un lecteur non statisticien.

### 2.2.4 Jalon 4 : sélection de variables

Objectif : comparer des modèles de façon rigoureuse.

Tâches :

- sélection pas à pas (`step()`) avec l'AIC et le BIC, et discussion des limites de cette approche, notamment l'inférence faite après sélection ;
- régularisation ridge et lasso avec `glmnet`, choix de  $\lambda$  par validation croisée ;
- comparaison du pouvoir prédictif par validation croisée, puis une évaluation finale du modèle retenu sur le jeu de réserve (taux de bonne classification, AUC et déviance pour la logistique ; erreur quadratique et déviance pour Poisson) ;
- examen de la stabilité : les variables retenues changent-elles si l'on rééchantillonne (bootstrap) ?

```
library(glmnet)
X <- model.matrix(y ~ ., donnees_propres)[, -1]
cv <- cv.glmnet(X, donnees_propres$y, family = "binomial", alpha = 1)
coef(cv, s = "lambda.1se")
```

Livrable : un tableau comparatif d'au moins trois modèles (complet, sélectionné, lasso), avec un choix final justifié.

### 2.2.5 Jalon 5 : ouverture sur d'autres modèles

Objectif : voir jusqu'où le GLM est adéquat et ce qui pourrait le remplacer ou le compléter.

Tâches (choisissez-en au moins une) :

- ajouter une relation non linéaire par splines ou par un GAM (`mgcv::gam()`) et comparer avec le GLM au moyen de l'AIC et de la validation croisée ;
- essayer une méthode de plus proches voisins ou à noyau pour la prédiction ;
- tester un modèle pour données surdispersées (quasi-Poisson, binomial négatif) ou avec excès de zéros (modèle à inflation de zéros) ;
- comparer avec une méthode d'apprentissage automatique (forêt aléatoire, arbre de décision) et discuter du compromis entre interprétabilité et prédiction.

```
library(mgcv)
gam1 <- gam(y ~ s(diametre) + s(hauteur) + espece, data = donnees_propres,
            family = binomial, method = "REML")
plot(gam1, pages = 1)
AIC(ajust, gam1)
```

Livrable : une demi-page répondant à la question « le GLM suffit-il ? », appuyée par au moins une comparaison chiffrée.

## 2.3 Évaluation

Le projet compte pour 45 % de la note finale.

| Composante                                           | Pondération |
|------------------------------------------------------|-------------|
| Livrables des jalons ( $5 \times 3 \%$ )             | 15 %        |
| Rapport technique                                    | 15 %        |
| Présentation et produit de communication             | 10 %        |
| Contribution individuelle (évaluation par les pairs) | 5 %         |
| <b>Total</b>                                         | <b>45 %</b> |

Critères d'évaluation du rapport et de la présentation :

- justesse statistique (modèle adapté, hypothèses vérifiées, inférence correcte) ;
- qualité de l'interprétation (claire, nuancée, liée à la question de départ) ;
- reproductibilité (le document se compile sans intervention) ;
- clarté de la communication (graphiques lisibles, vulgarisation) ;
- profondeur de l'analyse (diagnostics, sélection de modèle, ouverture).

## 2.4 Calendrier suggéré

La date de chaque labo sert d'échéance au jalon correspondant (voir le [calendrier du cours](#) et l'onglet [Labos](#)). Vous pouvez compléter un jalon avant cette date ; il n'est pas nécessaire d'attendre le labo, ni de faire le travail en classe.

| Jalon                                     | Échéance         |
|-------------------------------------------|------------------|
| Jalon 1 : choix du jeu de données         | Labo 1 — 11 mars |
| Jalon 2 : nettoyage et analyse primaire   | Labo 2 — 18 mars |
| Jalon 3 : ajustement et début d'inférence | Labo 3 — 25 mars |
| Jalon 4 : sélection de variables          | Labo 4 — 1 avril |
| Jalon 5 : ouverture sur d'autres modèles  | Labo 5 — 8 avril |
| Présentations                             | 22 avril         |

STT-4300 — Régression II

## 3 Labo 1

### Note

Ce labo sera disponible à partir du 11 mars 2027.

STT-4300 — Régression II

## 4 Labo 2

### Note

Ce labo sera disponible à partir du 18 mars 2027.

STT-4300 — Régression II

## 5 Labo 3

### Note

Ce labo sera disponible à partir du 25 mars 2027.

STT-4300 — Régression II

## 6 Labo 4

### **i** Note

Ce labo sera disponible à partir du 1er avril 2027.

STT-4300 — Régression II

## 7 Labo 5

### **i** Note

Ce labo sera disponible à partir du 8 avril 2027.