

Projet de session et laboratoires

STT-4300 – Régression II

Julien Miron

Hiver 2027 – ébauche

Table des matières

1	Projet de session	1
1.1	Vue d'ensemble	1
1.2	Modalités	2
1.3	Choix du jeu de données	2
1.4	Livrable final	3
1.5	Contenu attendu du rapport	3
2	Laboratoires	4
2.1	Labo 1 : choix du jeu de données	4
2.2	Labo 2 : nettoyage et analyse primaire	4
2.3	Labo 3 : ajustement et début d'inférence	5
2.4	Labo 4 : sélection de variables	5
2.5	Labo 5 : ouverture sur d'autres modèles	6
3	Évaluation	6
4	Calendrier suggéré	7
5	Idées supplémentaires	7

1 Projet de session

1.1 Vue d'ensemble

Le projet de session consiste à mener, en équipe, une analyse complète d'un jeu de données à l'aide d'un GLM : une régression logistique (réponse binaire ou proportion) ou une régression de Poisson (réponse de comptage). Le choix du modèle et du jeu de données revient à l'équipe, sous réserve de l'approbation de l'enseignant au Labo 1.

Le projet avance par étapes, au rythme des cinq laboratoires faits en classe. Chaque laboratoire produit un livrable court qui s'intègre au rapport final, de sorte qu'il n'y a pas de gros bloc de travail à la fin de la session.

Objectif général : passer d’une question concrète à un modèle défendable, c’est-à-dire un modèle dont on sait expliquer le choix, vérifier l’ajustement, interpréter les coefficients et reconnaître les limites.

1.2 Modalités

- Équipes de 3 ou 4 étudiants, formées au Labo 1.
- Un dépôt GitHub (ou un dossier partagé) par équipe, avec un projet R reproductible (`renv` recommandé). L’enseignant a accès au dépôt.
- Tout le code est en R et le rapport est rédigé en Quarto ou en $\text{\LaTeX}$: le document doit se compiler de zéro sans intervention manuelle.
- Chaque livrable contient une courte section « Contributions » indiquant qui a fait quoi.

1.3 Choix du jeu de données

Un jeu de données convenable respecte les critères suivants.

1. Une variable réponse Y claire : binaire (ou proportion y_i/n_i) pour la régression logistique, ou comptage pour la régression de Poisson.
2. Au moins $n = 200$ observations et au moins 6 covariables potentielles, avec un mélange de variables quantitatives et qualitatives.
3. Une question de recherche qu’on peut énoncer en une phrase.
4. Des données libres de droits et sans information permettant d’identifier des personnes.
5. Un peu de désordre (valeurs manquantes, catégories rares, valeurs aberrantes), parce que le nettoyage fait partie de l’exercice.

Jeux de données proposés.

Jeu de données	Modèle naturel	Question possible
<code>empress_individus.csv</code> , <code>empress_agrege.csv</code> <code>arbres.csv</code> (200 arbres, 4 espèces)	logistique (binaire ou binomiale agrégée) logistique	Quels facteurs ont influencé la survie lors du naufrage de l’Empress of Ireland ? Un arbre est-il dominant ou codominant, selon son diamètre, sa hauteur et son espèce ?
<code>qualite_air.csv</code> (42 stations, données horaires 2025)	Poisson (nombre de dépassements par station et par mois) ou logistique (dépassement d’un seuil)	Quels polluants et quelles périodes sont associés aux épisodes de mauvaise qualité de l’air ?

Les équipes peuvent aussi proposer leur propre jeu de données, par exemple à partir de Données

Québec, de Statistique Canada, du dépôt UCI, de Kaggle ou de données ouvertes de la Ville de Québec (collisions, 311, bacs de recyclage, etc.).

Attention aux jeux de données avec très peu de dimensions (comme l'Empress, qui n'a que trois covariables catégorielles). Ils conviennent bien pour comprendre le modèle, mais laissent peu de place à la sélection de variables du Labo 4. Une équipe qui choisit l'Empress devra enrichir l'analyse (interactions, comparaison avec d'autres modèles).

1.4 Livrable final

Le projet se termine par une présentation en classe (10 minutes plus 5 minutes de questions) accompagnée d'un produit de communication, au choix de l'équipe :

- une application Shiny qui permet d'explorer le modèle (prédictions selon les valeurs des covariables, effet d'une variable, diagnostics) ;
- un site web Quarto (ou un tableau de bord) racontant l'analyse ;
- un poster scientifique (format 36×48 po) ;
- un autre format du même niveau, à proposer à l'enseignant (balado, bande dessinée statistique, vidéo de 5 minutes, etc.).

Peu importe le format, l'équipe doit aussi remettre un rapport technique de 8 à 12 pages qui rassemble les livrables des laboratoires et la conclusion.

Le produit de communication s'adresse à un public non statisticien. La présentation doit donc traduire les résultats en langage clair : on parle de rapport de cotes ou de variation en pourcentage du taux, pas seulement de coefficients $\hat{\beta}_j$.

1.5 Contenu attendu du rapport

1. Question de recherche et description des données.
2. Nettoyage et analyse exploratoire.
3. Modèle retenu, avec sa justification.
4. Estimation, intervalles de confiance et tests (valeur- p) pour les paramètres d'intérêt.
5. Sélection de variables et comparaison de modèles.
6. Diagnostics et validation (résidus, observations influentes, surdispersion pour Poisson, calibration et courbe ROC pour la logistique, validation croisée).
7. Interprétation, limites et ouverture vers d'autres modèles.

2 Laboratoires

Les cinq laboratoires ont lieu en classe, pendant environ une heure chacun. L'enseignant circule entre les équipes. Chaque laboratoire se termine par un livrable court (une à deux pages ou un fichier source) à remettre dans la semaine qui suit.

2.1 Labo 1 : choix du jeu de données

Objectif : former les équipes, choisir une question de recherche et valider la faisabilité.

Tâches en classe :

- explorer au moins deux jeux de données candidats avec `str()`, `summary()` et `skimr::skim()` ;
- énoncer une question de recherche et identifier la variable réponse Y ainsi que les covariables potentielles ;
- justifier le choix entre logistique et Poisson ;
- vérifier les critères du choix de jeu de données ci-dessus.

Pour un jeu de données de collisions routières par intersection, on pourrait poser $Y_i \sim \text{Poisson}(\mu_i)$ avec

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip},$$

où t_i est une mesure d'exposition (ici, le trafic moyen) qui entre dans le modèle comme décalage (`offset`).

Livrable : une page de proposition (question, données, variable réponse, modèle envisagé, répartition des tâches). L'enseignant l'approuve ou demande des ajustements.

2.2 Labo 2 : nettoyage et analyse primaire

Objectif : connaître ses données avant de modéliser.

Tâches en classe :

- documenter les variables (type, unité, valeurs permises) dans un dictionnaire de données ;
- traiter les valeurs manquantes (quantifier, comprendre le mécanisme, choisir une stratégie et la justifier) ;
- recoder les variables qualitatives (niveaux rares, catégorie de référence) ;
- produire des statistiques descriptives et des graphiques de Y en fonction de chaque covariable ;
- repérer les valeurs aberrantes et les problèmes de colinéarité (corrélations, facteurs d'inflation de la variance).

```
library(tidyverse)
donnees <- read_csv("arbres.csv")
```

```
# proportion de Y selon une covariable qualitative
donnees |>
  group_by(species_fr) |>
  summarise(n = n(), prop = mean(y), .groups = "drop")

# valeurs manquantes
donnees |> summarise(across(everything(), ~ mean(is.na(.x))))
```

Livrable : un fichier source qui part des données brutes et produit les données nettoyées, avec une section expliquant chaque décision prise.

2.3 Labo 3 : ajustement et début d'inférence

Objectif : ajuster un premier GLM et interpréter les résultats.

Tâches en classe :

- ajuster un modèle complet avec `glm()` ;
- interpréter chaque coefficient sur l'échelle du prédicteur linéaire et sur l'échelle naturelle (rapport de cotes $e^{\hat{\beta}_j}$ ou rapport de taux) ;
- construire des intervalles de confiance de Wald et par vraisemblance profilée (`confint()`), puis comparer ;
- effectuer des tests de Wald et des tests du rapport de vraisemblance, en précisant la valeur- p et l'hypothèse testée ;
- tracer l'effet d'une covariable sur la probabilité (ou le taux) prédite, les autres covariables étant fixées.

```
ajust <- glm(y ~ ., data = donnees_propres, family = binomial) # ou poisson
summary(ajust)
exp(cbind(OR = coef(ajust), confint(ajust)))
anova(ajust, test = "Chisq")
```

Pour Poisson, on vérifie dès cette étape la surdispersion en comparant la déviance résiduelle à ses degrés de liberté. Si le rapport est nettement supérieur à 1, on passe à un modèle quasi-Poisson ou binomial négatif.

Livrable : une page d'interprétation écrite pour un lecteur non statisticien.

2.4 Labo 4 : sélection de variables

Objectif : comparer des modèles de façon rigoureuse.

Tâches en classe :

- sélection pas à pas (`step()`) avec l'AIC et le BIC, et discussion des limites de cette approche, notamment l'inférence faite après sélection ;
- régularisation ridge et lasso avec `glmnet`, choix de λ par validation croisée ;
- comparaison du pouvoir prédictif par validation croisée (taux de bonne classification, AUC et déviance pour la logistique ; erreur quadratique et déviance pour Poisson) ;
- examen de la stabilité : les variables retenues changent-elles si l'on rééchantillonne (bootstrap) ?

```
library(glmnet)
X <- model.matrix(y ~ ., donnees_propres)[, -1]
cv <- cv.glmnet(X, donnees_propres$y, family = "binomial", alpha = 1)
coef(cv, s = "lambda.1se")
```

Livrable : un tableau comparatif d'au moins trois modèles (complet, sélectionné, lasso), avec un choix final justifié.

2.5 Labo 5 : ouverture sur d'autres modèles

Objectif : voir jusqu'où le GLM est adéquat et ce qui pourrait le remplacer ou le compléter.

Tâches en classe (chaque équipe en choisit au moins une) :

- ajouter une relation non linéaire par splines ou par un GAM (`mgcv::gam()`) et comparer avec le GLM au moyen de l'AIC et de la validation croisée ;
- essayer une méthode de plus proches voisins ou à noyau pour la prédiction ;
- tester un modèle pour données surdispersées (quasi-Poisson, binomial négatif) ou avec excès de zéros (modèle à inflation de zéros) ;
- comparer avec une méthode d'apprentissage automatique (forêt aléatoire, arbre de décision) et discuter du compromis entre interprétabilité et prédiction.

```
library(mgcv)
gam1 <- gam(y ~ s(diametre) + s(hauteur) + espece, data = donnees_propres,
            family = binomial, method = "REML")
plot(gam1, pages = 1)
AIC(ajust, gam1)
```

Livrable : une demi-page répondant à la question « le GLM suffit-il ? », appuyée par au moins une comparaison chiffrée.

3 Évaluation

La pondération suivante est une suggestion à ajuster selon le plan de cours.

Composante	Pondération
Livrables des laboratoires ($5 \times 3\%$)	15 %
Rapport technique	15 %
Présentation et produit de communication	10 %
Contribution individuelle (évaluation par les pairs)	5 %
Total (note finale)	45 %

Grille pour le rapport et la présentation :

- justesse statistique (modèle adapté, hypothèses vérifiées, inférence correcte) ;
- qualité de l'interprétation (claire, nuancée, liée à la question de départ) ;
- reproductibilité (le document se compile sans intervention) ;
- clarté de la communication (graphiques lisibles, vulgarisation) ;
- profondeur de l'analyse (diagnostics, sélection de modèle, ouverture).

4 Calendrier suggéré

Semaine	Matière en cours	Activité
3	Régression logistique	Labo 1 : choix du jeu de données
5	GLM, Poisson	Labo 2 : nettoyage et analyse primaire
7	GLM, inférence	Labo 3 : ajustement et inférence
10	Validation croisée, régularisation	Labo 4 : sélection de variables
12	Splines, GAM	Labo 5 : ouverture
14		Présentations

5 Idées supplémentaires

Quelques ajouts à retenir ou non.

- Un point de contrôle informel à mi-parcours (5 minutes par équipe) pour détecter tôt les équipes en difficulté.
- Un jeu de données de réserve : chaque équipe met de côté 20 % des observations, qu'elle n'utilise qu'à la fin pour évaluer le modèle final. Cela rend la comparaison de modèles du Labo 4 plus honnête.
- Une section obligatoire « Ce qui pourrait fausser nos conclusions » (biais de sélection, variables omises, causalité et corrélation).
- Une courte réflexion éthique pour les jeux de données touchant des personnes (qui est dans les données, qui n'y est pas).
- Une évaluation par les pairs des présentations, pour que chaque équipe lise au moins un

autre projet.

- Un modèle de rapport fourni par l'enseignant, avec les environnements du livre, pour uniformiser la présentation.